

1. 문제 정의와 사용 목적

목적: UCI Heart Disease 데이터 기반 심장 위험 신호 예측을 개인 사용자가 이해할 수 있는 대응 가이드로 바꿉니다.

핵심 원칙: CardioCare는 inform, not decide 원칙의 상담 준비 보조 도구이며 전문적인 의학 진단이나 치료 결정을 대신하지 않습니다.

주의: 이 리포트와 예측 결과는 전문적인 의학 진단이 아니며, 치료 결정은 보건실 또는 의료진과 상의해야 합니다.

데이터: data/processed.cleveland.data의 UCI Cleveland 데이터를 사용합니다.

타겟 이진화: UCI target 0은 정상, 1~4는 심장병 있음으로 변환합니다.

출력: 심장 위험 확률, action level, 대응 행동, 상담 질문, 의료진에게 보여줄 visit summary입니다.

응급 증상 입력이 true이면 모델 확률보다 사람의 안전을 우선하여 urgent로 라우팅합니다.

2. EDA 핵심 결과

데이터셋: UCI processed Cleveland, 303 rows, 13 clinical features.

타겟 분포: normal 0.541, heart disease 0.459.

평가 지표 선택: 클래스 균형과 false negative 비용을 고려해 balanced accuracy와 recall을 핵심 지표로 둡니다.

결측값: 전체 6, 열별 {'ca': 4, 'thal': 2}.

중복 행: 0; 빈 컬럼은 학습 전 제거합니다.

IQR 이상치 수: age 0, trestbps 9, chol 5, thalach 1, oldpeak 5.

결측값은 삭제 대신 median 또는 most-frequent imputation으로 처리해 303개 표본을 보존합니다.

이상치는 제거하지 않고 boxplot 근거로 표시만 하며, 임상적으로 의미 있는 고혈압·고콜레스테롤 신호로 남깁니다.

notebooks/01_eda_preprocessing.ipynb는 head(), info(), describe(), target 분포, 결측값, 중복, boxplot, IQR 이상치 탐지를 포함합니다.

그림 1 캡션: target 분포가 완전 불균형은 아니지만 false negative 비용 때문에 recall과 balanced accuracy를 함께 봅니다.

그림 2 캡션: 연속형 boxplot은 trestbps, chol, oldpeak의 극단값을 보여 주며 제거보다 검증과 보존을 선택한 근거입니다.



3. 전처리 결정

연속형 변수는 median imputation 후 StandardScaler를 적용합니다.

범주형 코드 변수는 most-frequent imputation 후 OneHotEncoder를 적용합니다.

chol [0, 600] 같은 임상 범위 검증을 추론 전 단계에 포함합니다.


이상치는 무조건 제거하지 않고, 의료적으로 의미 있는 극단값일 수 있어 분석 대상으로 남깁니다.

빈 컬럼은 학습 전 제거하고 중복 행은 prepare_model_data에서 제거합니다.

스케일러, 임퓨터, OneHotEncoder, SelectFromModel은 train_test_split 이후 sklearn Pipeline 내부에서 fit되어 데이터 누수를 막습니다.

EDA 연결: 결측이 ca와 thal에 소수로 집중되어 삭제보다 대체를 선택했고, target 분포 때문에 단순 accuracy 대신 balanced accuracy와 recall을 사용합니다.

EDA 연결: IQR 이상치가 있는 chol, trestbps, oldpeak는 심혈관 위험 신호일 수 있어 학습에서 제거하지 않고 입력 범위 검증으로 통제합니다.



4. MLflow 모델 비교와 최종 선택

MLflow 모델 비교 표: model | balanced accuracy | precision | recall | F1 | confusion matrix

Logistic Regression: 0.9064 | 0.8438 | 0.9643 | 0.9000 | [[28, 5], [1, 27]]

SVC: 0.9367 | 0.9000 | 0.9643 | 0.9310 | [[30, 3], [1, 27]]

Random Forest: 0.8885 | 0.8387 | 0.9286 | 0.8814 | [[28, 5], [2, 26]]

Balanced Accuracy: 0.9064

Precision: 0.8438

Recall: 0.9643

F1: 0.9000

Threshold: 0.48

Confusion Matrix: [[28, 5], [1, 27]]

선택된 주요 원본 feature: ['age', 'trestbps', 'chol', 'thalach', 'oldpeak', 'sex', 'cp', 'exang', 'slope', 'ca', 'thal']

Logistic Regression, SVC, Random Forest를 비교하고, 5-fold CV와 GridSearchCV를 수행했습니다.


최종 모델은 false negative를 줄이기 위해 recall과 balanced accuracy를 함께 보는 threshold tuned Logistic Regression입니다.

SVC는 balanced accuracy가 더 높지만 Logistic Regression threshold tuned는 같은 recall과 같은 false negative 수를 유지하면서 threshold 해석이 쉽습니다.

임상적으로 해석 가능한 특성: age, trestbps, chol, thalach, oldpeak, cp, exang은 혈압·지질·운동 반응·흉통 신호와 직접 연결됩니다.

MLflow에는 파라미터, 지표, confusion_matrix.json, selected_features.json, 모델 artifact, model_family tag를 기록합니다.

그림 3 캡션: 모델 비교 그래프는 balanced accuracy와 recall을 나란히 보여 주며, 최종 선택이 recall 중심 안전 전략임을 확인합니다.



5. 테스트와 패키징

unittest는 예측 shape, 확률 범위와 행별 합, 임상 범위 검증, 고정 시드 결정론을 검사합니다.

추가 테스트는 음료 로그 요약, urgent/consult action routing, 상담 질문, visit summary 필드를 검증합니다.

Dockerfile은 requirements.txt 기반 의존성 설치 후 저장된 모델과 코드를 복사하고 샘플 CSV batch inference를 실행합니다.

GitHub Actions는 push와 pull_request에서 의존성 설치, python src/train.py, python src/monitor.py, python -m unittest, Docker build/run을 실행합니다.

Feature store 후보: cholesterol. 추론 입력, 임상 해석, drift monitoring 모두에서 핵심 특성이기 때문입니다.

Model registry metadata 후보: tuned threshold. false negative와 보수적 상담 권고의 tradeoff를 결정하기 때문입니다.

6. 드리프트 결과와 재학습 계획

원본 테스트셋 Balanced Accuracy: 0.9063852813852814

드리프트 테스트셋 Balanced Accuracy: 0.8333333333333333

성능 변화량: -0.07305194805194815

monitor.py는 chol 평균을 이동시키고 oldpeak 변동을 키운 합성 테스트셋을 만듭니다.

각 연속형 특성에는 scipy.stats.ks_2samp를 적용하며 $p < 0.05$ 인 특성을 drift로 플래그합니다.

age: KS=0.0876, p-value=0.8124, drift=False

trestbps: KS=0.1384, p-value=0.2762, drift=False

chol: KS=0.7029, p-value=6.575e-24, drift=True

thalach: KS=0.4967, p-value=1.749e-11, drift=True

oldpeak: KS=0.5579, p-value=1.363e-14, drift=True

재학습 정책: $p < 0.05$ drift가 반복되고 balanced accuracy 하락이 확인되면 새 라벨 검토 후 재학습합니다.

정기 재학습은 월 1회 후보로 두되, drift trigger가 있으면 우선순위를 높입니다.

로깅 근거: 일반 inference는 actual label이 없을 수 있지만 monitor 경로는 test label을 actual label로 함께 저장해 예측값과 정답을 대조합니다.

폭주 피드백 루프 위험: 모델 권고가 사용자 행동과 라벨 수집을 바꾸면 편향된 새 데이터가 누적될 수 있습니다.

Human-in-the-loop: consult, urgent, low-confidence, drift-triggered retraining 후보는 보건실 또는 의료진 검토를 거칩니다.

7. 서빙 선택

서빙 선택: Model-as-a-Service를 선택합니다.

지연 시간: 현재 입력은 13개 영상 특성의 batch 또는 단건 추론이므로 서버 호출 지연은 허용 가능한 범위입니다.

개인정보(PHI): 온디바이스보다 중앙 서버가 민감정보 집중 위험이 있으므로 최소 입력, 로그 비식별화, 접근 통제가 필요합니다.

업데이트 주기: 모델 threshold와 drift 대응 정책을 빠르게 교체해야 하므로 서버형 배포가 온디바이스보다 관리하기 쉽습니다.

운영 방식: Docker 이미지는 저장된 모델 artifact로 추론하며, inference.py는 timestamp, model version, input shape, prediction을 파일 로그로 남깁니다.

8. 한계, 윤리, AI 도구 사용 공개

한계: Cleveland 데이터는 규모가 작고 오래된 임상 데이터라 실제 대학생 집단이나 지역 의료 환경을 대표하지 못할 수 있습니다.

윤리: 예측 결과는 전문적인 의학 진단이 아닌 상담 준비 자료이며, emergency warning symptoms는 모델 확률보다 우선합니다.

한 주가 더 주어진다면 calibration curve, 외부 검증 데이터, clinician review checklist, 더 명확한 PHI 로그 정책을 추가합니다.

AI 도구 사용 공개: ChatGPT/Codex를 보일러플레이트 정리, 디버깅, 요구사항 대조에 사용했으며 최종 코드와 결과 해석의 책임은 제출자가 집니다.

근거 자료: CDC Heart Disease Prevention, CDC Risk Factors, AHA Life's Essential 8, AHA Heart Attack Warning Signs.