

CardioCare Action Navigator

목적: UCI Heart Disease 데이터 기반 심장 위험 신호 예측을 개인 사용자가 이해할 수 있는 대응 가이드로 바꿉니다.

핵심 원칙: 이 서비스는 진단하거나 치료를 결정하지 않습니다. inform, not decide 원칙의 상담 준비 보조 도구입니다.

데이터: 제출된 heart+disease.zip 또는 data/heart+disease/processed.cleveland.data의 processed.cleveland.data를 사용합니다.

타겟 이진화: UCI target 0은 정상, 1~4는 심장병 있음으로 변환합니다.

출력: 심장 위험 확률, action level, 대응 행동, 상담 질문, 의료진에게 보여줄 visit summary를 제공합니다.

EDA 및 전처리

노트북은 head(), info(), describe(), target 분포, 결측값, 중복, IQR 기반 이상치 탐지를 포함합니다.

타겟 분포를 확인해 단순 accuracy뿐 아니라 balanced accuracy와 recall을 주요 지표로 사용합니다.

연속형 변수는 median imputation 후 StandardScaler를 적용합니다.

범주형 코드 변수는 most-frequent imputation 후 OneHotEncoder를 적용합니다.

chol [0, 600] 같은 임상 범위 검증을 추론 전 단계에 포함합니다.

이상치는 무조건 제거하지 않고, 의료적으로 의미 있는 극단값일 수 있어 분석 대상으로 남깁니다.

모델 학습 및 MLflow

Balanced Accuracy: 0.9064

Precision: 0.8438

Recall: 0.9643

F1: 0.9000

Threshold: 0.48

Confusion Matrix: $\begin{bmatrix} 28 & 5 \\ 1 & 27 \end{bmatrix}$

선택된 주요 원본 feature: ['age', 'trestbps', 'chol', 'thalach', 'oldpeak', 'sex', 'cp', 'exang', 'slope', 'ca', 'thal']

Logistic Regression, SVC, Random Forest를 비교하고, 5-fold CV와 GridSearchCV를 수행합니다.

최종 모델은 심장 위험 신호를 놓치는 false negative를 줄이기 위해 recall을 중요하게 봅니다.

MLflow에는 파라미터, 지표, confusion matrix, 선택 feature, 모델 artifact, model_family tag를 기록합니다.

Action Navigator 결과

heart_probability_percent: 사용자가 이해하기 쉬운 백분율 예측값입니다.

action_level: low, watch, consult, urgent 중 하나를 반환합니다.

response_actions: 사용자가 지금 확인할 사항과 다음 행동을 제시합니다.

consultation_questions: 보건실 또는 의료진 상담 때 물어볼 질문을 생성합니다.

visit_summary: 확률, 등급, 주요 요인, 핵심 수치, disclaimer를 담은 상담용 요약 카드입니다.

응급 증상 입력이 true이면 모델 확률과 무관하게 urgent로 라우팅합니다.

모니터링 및 드리프트

원본 테스트셋 Balanced Accuracy: 0.9063852813852814

드리프트 테스트셋 Balanced Accuracy: 0.8912337662337663

성능 변화량: -0.0151515151515138

monitor.py는 chol 분포를 인위적으로 이동시키고 scipy.stats.ks_2samp로 연속형 feature drift를 감지합니다.

age: p-value=0.8124, drift=False

trestbps: p-value=0.2762, drift=False

chol: p-value=6.052e-06, drift=True

thalach: p-value=0.9517, drift=False

oldpeak: p-value=0.02944, drift=True

배포, CI, 윤리

Dockerfile은 python src/train.py 이후 생성된 모델 artifact로 batch inference를 실행할 수 있게 구성되어 있습니다.

GitHub Actions는 push마다 python -m unittest를 실행합니다.

Human-in-the-loop: consult, urgent, low-confidence 결과는 보건실 또는 의료진 검토를 권장합니다.

Feature store 후보: cholesterol. 추론과 drift monitoring 모두에서 사용되기 때문입니다.

Model registry metadata 후보: tuned threshold. false negative tradeoff를 결정하는 핵심 값이기 때문입니다.

근거 자료: CDC Heart Disease Prevention, CDC Risk Factors, AHA Life's Essential 8, AHA Heart Attack Warning Signs.