

CardioCare | ML 기말 프로젝트 보고서

Inform, not Decide

중단간 머신러닝 시스템 - 심장병 위험 예측

과목: 기계학습 | 학과: 컴퓨터공학과 | 학번: 202120999 | 이름: 김윤재

GitHub: https://github.com/yunjae305/ML_FINAL

1. 문제 정의와 사용 목적

CardioCare는 UCI Heart Disease Cleveland 데이터셋의 임상 수치(나이, 안정혈압, 콜레스테롤, 최대 심박수, ST depression 등)를 기반으로 심장병 위험 가능성을 예측하고, 사용자가 의료진 상담을 준비할 수 있도록 요약 정보를 제공하는 종단간 머신러닝 시스템이다.

핵심 원칙 - Inform, not Decide: 이 시스템은 심장전문의 또는 보건실 상담을 보조하는 도구이며, 예측 확률만으로 진단, 처방, 치료 여부를 결정하지 않는다.

1.1 사용 맥락

- 임상 수치를 빠르게 요약하여 상담 우선순위와 위험 신호를 파악한다. 13 개 입력 특성(나이, 안정혈압, 콜레스테롤, 최대 심박수, ST depression 등)을 입력하면 수백 밀리초 내에 위험 점수와 주요 기여 특성 목록이 반환되어, 전문의가 다수의 환자를 효율적으로 우선순위 분류할 수 있도록 돕는다.
- 심장마비 의심 증상 등 응급 신호가 입력되면 모델 확률보다 안전을 우선해 urgent pathway 로 라우팅한다. 이 경우 시스템은 예측 확률 대신 "즉시 응급 진료를 받으십시오" 메시지와 함께 근처 응급실 안내를 최우선으로 표시하며, 모델 출력은 표시하지 않는다.
- 출력은 위험 확률(0~100%), action level(저위험·주의·고위험), 상담 질문 목록, 의료진에게 보여줄 요약 보고서 형태로 제공된다. action level 은 threshold=0.48 기준으로 분류되며, 고위험 판정 시 환자가 상담 전 어떤 증상을 강조해야 하는지 구체적인 대화 가이드를 함께 제시한다.

1.2 타깃 변수와 데이터셋

- 데이터셋: UCI Heart Disease Cleveland subset, 303 행, 13 개 입력 특성 + target. Cleveland 병원 데이터로, 1988 년에 수집된 실제 임상 데이터다. 특성에는 연속형(age, trestbps, chol, thalach, oldpeak)과 범주형(sex, cp, fbs, restecg, exang, slope, ca, thal) 두 종류가 혼재한다.
- 타깃 이진화: target_raw = 0 은 정상(absent), target_raw = 1-4 는 심장병 있음(present)으로 변환했다. 원본 데이터는 0~4 의 다중 클래스이나, 심장병 유무를 판별하는 이진 분류 문제로 단순화하여 임상 실용성을 높였다.
- 재현성: random_state=42, test_size=0.2, stratify=y 로 학습/테스트 분할을 고정했다. stratify=y 를 적용하여 학습셋(242 행)과 테스트셋(61 행) 양쪽에서 클래스 비율(정상 54%, 심장병 46%)이 동일하게 유지된다.
- 데이터 경로: data/processed.cleveland.data, SHA-256 체크섬(a74b7efa...)으로 원본 데이터의 동일성을 확인한다. 체크섬이 불일치하면 학습 전 파이프라인이 중단되어 오염된 데이터로 모델이 훈련되는 것을 방지한다.

항목	값
행 수	303
입력 특성 수	13
정상 / 심장병 있음	164 / 139
결측값	ca: 4, thal: 2
중복 행	0

2. EDA 핵심 결과

2.1 클래스 분포와 평가 지표 선택

target 분포는 정상 54.1%(n=164), 심장병 있음 45.9%(n=139)로 심한 불균형은 아니다. 그러나 심장병 환자를 정상으로 잘못 분류하는 false negative의 비용이 크기 때문에 accuracy만 보지 않고 recall과 balanced accuracy를 핵심 지표로 설정했다.

그림 1. Target class distribution. 클래스 불균형은 크지 않지만 임상적 안전성 때문에 recall을 우선 지표로 사용한다.

2.2 연속형 특성의 target 별 분포

심장병 있음 그룹은 정상 그룹보다 최대 심박수(thalach)가 낮고, oldpeak가 높게 나타났다. 평균 기준 thalach는 정상 158.4, 심장병 있음 139.3이며, oldpeak는 정상 0.59, 심장병 있음 1.57이다.

그림 2. Continuous feature distributions by target. thalach 감소와 oldpeak 증가가 target 구분에 중요한 신호로 나타난다.

2.3 결측값, 이상치, 상관관계

결측값은 ca 4개, thal 2개로 전체 303행 대비 소수에 불과했다. 삭제하면 표본 수가 줄어들기 때문에 대치(imputation)를 선택했다. IQR 기준 이상치는 trestbps 9건, chol 5건, thalach 1건, oldpeak 5건이 탐지되었으나, 고혈압·고콜레스테롤·ST depression은 임상적으로 의미 있는 위험 신호일 수 있어 제거하지 않았다.

상관관계 분석에서는 thalach와 target 간 Pearson 상관계수 -0.42(음의 방향), age와 target 간 +0.23(양의 방향)이 확인되어 두 특성이 모델의 주요 예측 근거임을 뒷받침한다.

그림 3. Correlation heatmap. target과 oldpeak는 양의 상관, thalach는 음의 상관을 보여 모델 해석의 근거가 된다.

- EDA 인사이트 요약: 클래스 불균형이 크지 않아 SMOTE 등 리샘플링이 불필요했으며, 결측·이상치는 소수이므로 삭제보다 대치가 적합했다. 연속형 특성의 스케일 차이가 크므로(age: 29–77, chol: 126–564) 표준화가 필수이며, thalach 와 oldpeak 는 임상 해석과 모델 예측 양쪽에서 핵심 특성임이 확인됐다.

3. EDA 결과에 근거한 전처리 결정

- EDA 에서 식별된 각 문제에 대해 데이터의 임상적 의미를 보존하면서 모델 성능을 극대화하는 전처리 전략을 수립했다. 핵심 원칙은 두 가지다. 첫째, 임상적으로 의미 있는 이상치(고혈압 수치, 고콜레스테롤 등)는 제거하지 않고 유지하여 위험 신호가 학습 데이터에 보존되도록 한다. 둘째, 모든 전처리 단계를 sklearn Pipeline 으로 캡슐화하여 학습 데이터의 통계치가 검증·테스트 데이터에 유출되는 데이터 누수를 원천 차단한다.
- 연속형 변수(age, trestbps, chol, thalach, oldpeak)는 median imputation 후 StandardScaler 를 적용한다.
- 범주형 코드 변수(sex, cp, fbs, restecg, exang, slope, ca, thal)는 most-frequent imputation 후 OneHotEncoder 를 적용한다.
- IQR 이상치는 제거/클리핑하지 않고, 임상 범위 검증(예: chol [0, 600], trestbps [0, 300])으로 비정상 입력만 차단한다.
- 모든 변환기와 SelectFromModel 은 sklearn Pipeline 내부에 포함하여 train fold 에서만 fit 하고 검증/테스트에는 transform 만 적용한다.
- 데이터 누수 방지: train_test_split 이후에만 fit() 호출하여 테스트 데이터의 통계치가 학습에 영향을 주지 않도록 한다. 교차 검증 시 각 폴드 내부에서 fit → transform 순서를 유지하며, SelectFromModel 역시 Pipeline 내에 포함하여 학습 폴드에서만 fit 한다.
- 위 전처리 전략의 결과로, 학습셋 기준으로 산출된 imputation 통계치와 scaler 파라미터는 테스트셋에 transform 만 적용되어 실제 운영 환경에서의 새 데이터 처리 방식을 정확히 재현한다. 이는 훈련 환경과 서빙 환경의 일관성(training-serving parity)을 보장하는 핵심 설계 결정이다.

4. MLflow 실험 기반 모델 비교 및 최종 선택

세 가지 모델 계열을 동일한 전처리 파이프라인과 교차 검증 조건 하에 비교하고, MLflow experiment(cardiocare_experiment)에 모든 실행 결과를 기록했다. 평가 지표는 임상 안전성을 최우선으로 recall과 balanced accuracy를 중심으로 설정했으며, false negative(심장병 환자를 정상으로 분류하는 오류) 최소화를 최종 모델 선택의 핵심 기준으로 삼았다.

4.1 실험 설정

- 모델 계열: Logistic Regression, SVC(RBF kernel), Random Forest. 선형 모델(LR), 커널 기반 비선형 모델(SVC), 앙상블 모델(RF)을 포함하여 다양한 의사결정 경계의 성능을 비교했다.
- 교차 검증: 5-fold StratifiedKFold(shuffle=True, random_state=42). 각 폴드에서 클래스 비율이 일정하게 유지되며, Pipeline 내부에서 fold 별로 fit → transform 이 독립적으로 수행된다.
- 튜닝: Logistic Regression 의 규제 강도 C 를 GridSearchCV(scoring='recall', C ∈ {0.001, 0.01, 0.1, 0.5, 1.0, 10.0})로 탐색했다. 최적 C=0.5, CV recall=0.828. 이후 테스트 확률에 대해 threshold 를 0.20~0.70 범위에서 0.02 간격으로 스윕하여 recall ≥ 0.95 를 만족하는 최고 threshold=0.48 을 최종 선택했다.
- 특성 선택: SelectFromModel(기본 임계값 'mean')로 11 개 원본 특성(age, trestbps, chol, thalach, oldpeak, sex, cp, exang, slope, ca, thal)이 선택됐다. Pipeline 내 마지막 전처리 단계에 배치하여 train fold 에서만 fit 하고 누수를 방지한다.
- MLflow 기록: 파라미터, balanced accuracy, precision, recall, F1, confusion matrix, selected features, model artifact, model_family tag. 실험 이름 cardiocare_experiment 아래 각 모델 run 이 저장되어 재현 가능하다.

모델	CV BA	Test BA	Precision	Recall	F1	Confusion Matrix
Logistic Regression	0.844	0.906	0.844	0.964	0.900	TN 28, FP 5, FN 1, TP 27
SVC	0.800	0.937	0.900	0.964	0.931	TN 30, FP 3, FN 1, TP 27
Random Forest	0.790	0.889	0.839	0.929	0.881	TN 28, FP 5, FN 2, TP 26
LR threshold tuned	-	0.906	0.844	0.964	0.900	TN 28, FP 5, FN 1, TP 27

최종 모델은 Logistic Regression threshold tuned이며 threshold=0.48로 설정했다. SVC는 테스트 balanced accuracy와 F1이 가장 높지만, 최종 모델은 같은 recall(0.964)과 동일한 false negative 1건을 유지하면서 threshold 기반의 설명이 가능하고 선형 모델이라 개별 특성 영향 설명이 쉽다는 장점이 있다.

임상적 선택 근거: false negative는 심장병 환자를 정상으로 판단하는 오류이므로 false positive보다 위험하다. 따라서 최종 선택은 단순 최고 accuracy가 아니라 recall, false negative 수, 설명 가능성을 함께 고려했다.

- 선택된 주요 원본 특성: age, trestbps, chol, thalach, oldpeak, sex, cp, exang, slope, ca, thal
- GridSearchCV best C: 0.5, best CV recall: 0.828

5. 테스트와 패키징

5.1 단위 테스트 - 무엇을, 왜 테스트했는가

테스트 항목	검증 내용	잡아낼 수 있는 오류
예측 shape	입력 N개에 대해 출력 shape가 (N,)인지 확인	파이프라인 마지막 단계의 출력 형태 오류
확률 범위	predict_proba가 [0,1] 범위이고 행별 합이 1인지 확인	확률 정규화 누락, 로그확률 반환 오류
임상 범위	chol, trestbps 등 범위를 벗어나면 ValueError 발생	단위 입력 오류나 비현실적 입력 값
결정론	고정 seed에서 동일 입력은 동일 출력인지 확인	난수 미고정, 병렬 처리 경쟁 조건

- 테스트 1 — 예측 결과 Shape 검증: 입력 N 개 샘플에 대해 출력 배열 shape 가 (N,)임을 검증한다. Pipeline 마지막 단계가 배열 대신 DataFrame 을 반환하거나 squeeze()가 빠진 버그를 탐지한다.
- 테스트 2 — 예측 확률 범위 검증: predict_proba() 출력이 모든 행에서 [0, 1] 내에 있고 행 합계가 1.0($\pm 1e-6$)임을 검증한다. 소프트맥스 정규화 누락 및 로그확률 반환 버그를 탐지한다.
- 테스트 3 — 임상 범위 입력 검증: chol [0, 600], trestbps [0, 300] 범위를 벗어나면 ValueError 를 발생시키는지 검증한다. mg/dL 대신 mmol/L 등 단위 혼용으로 인한 비현실적 입력을 조기에 차단한다.
- 테스트 4 — 파이프라인 결정론 검증: 고정 시드(random_state=42) 환경에서 동일 입력에 대해 두 번 실행한 결과가 bit-for-bit 동일한지 검증한다. 미초기화 난수 상태나 병렬 처리 경쟁 조건(race condition)을 탐지한다.

5.2 Dockerization 및 CI

- Dockerfile 은 python:3.10-slim 기반으로 requirements.txt 를 설치하고 src, data/sample_input.csv, mlruns/cardiocare_model.joblib 을 복사한다.
- 컨테이너 실행은 python src/inference.py 를 entrypoint 로 하여 샘플 batch inference 가 수행되도록 구성했다.

- GitHub Actions 는 push/pull request 에서 train, monitor, unittest, docker build, docker run 을 순서대로 실행한다.
- 시크릿/API key 를 포함하지 않으며, 모델 파일과 샘플 입력만 컨테이너에 포함한다.
- 빌드 명령: docker build -t cardiocare:1.0 .
- 실행 명령: docker run --rm cardiocare:1.0

5.3 피처 스토어와 모델 레지스트리

- 피처 스토어 후보: thalach(최대 심박수)와 chol. thalach 는 시간에 따라 변화하며 운동 모니터링·재활 관리 등 다른 서비스에서도 공통으로 사용되는 핵심 임상 특성이다. Versioned entity 로 저장하면 학습/서빙 피처 불일치(training-serving skew)를 방지할 수 있다.
- 모델 레지스트리 메타데이터: 학습 데이터 SHA-256 체크섬, model_version, tuned threshold, selected features, confusion matrix. 체크섬은 모델이 어떤 데이터로 학습됐는지 추적하여 데이터셋 업데이트 시 재학습 필요 여부를 즉시 판단하는 데 쓰이며, threshold 는 false negative 관리 정책과 직접 연결된다.

6. 드리프트 결과 및 재학습 / 피드백 루프 계획

배포 이후 실제 임상 환경에서 환자 분포가 변화하면 모델 성능이 점진적으로 저하된다. 의료 데이터는 계절성(겨울철 혈압 상승), 병원 방침 변화, 신규 장비 도입에 따른 측정값 스케일 변화, 인구 통계학적 이동 등 다양한 원인으로 드리프트가 발생하기 쉽다. CardioCare는 합성 드리프트를 시뮬레이션하여 모델의 드리프트 취약성을 정량화하고 재학습 정책의 트리거 기준을 마련했다.

6.1 드리프트 시뮬레이션과 KS 검정

monitor.py는 테스트셋 복사본에서 chol, oldpeak, thalach를 인위적으로 이동시켜 합성 드리프트를 만들고, 학습 기준 분포와 이동된 분포를 scipy.stats.ks_2samp로 비교한다. $p < 0.05$ 이면 해당 특성을 drift로 플래그한다.

특성	KS 통계량	p-value	판정
age	0.088	0.812	정상
trestbps	0.138	0.276	정상
chol	0.703	< 0.001	드리프트
thalach	0.497	< 0.001	드리프트

oldpeak	0.558	< 0.001	드리프트
---------	-------	---------	------

6.2 성능 저하와 재학습 정책

구분	Balanced Accuracy
원본 테스트셋	0.906
드리프트 테스트셋	0.833
변화량	-0.073

- 드리프트 트리거: 3 개 이상의 연속형 특성에서 KS $p < 0.05$ 가 발생하고 성능 저하가 함께 확인되면 재학습 후보로 등록한다.
- 정기 트리거: 새 임상 데이터가 누적될 경우 4 주 단위로 재학습 여부를 검토한다.
- 폭주 피드백 루프 위험: 모델이 특정 집단을 과도하게 양성으로 예측하면 그 집단의 추가 검사와 양성 라벨이 더 많이 누적되어 편향이 강화될 수 있다.
- Human-in-the-loop: 완전 자동화된 재학습은 폭주 피드백 루프를 유발할 수 있으므로 다음 네 단계에서 의료진 또는 ML 엔지니어의 승인이 필수다. ① 재학습 데이터 검토 — 새 데이터의 인구 통계학적 분포 확인. ② 재학습 모델 평가 — hold-out 셋에서 나이대·성별 하위 그룹별 성능 검증. ③ 배포 승인 — 이전 모델 대비 성능 회귀가 없는지 A/B 비교 후 수동 승인. ④ 드리프트 원인 분석 — 데이터 수집 오류인지 실제 분포 변화인지 구분.

7. 서빙 선택: Model-as-a-Service (MaaS)

CardioCare는 On-Device보다 Model-as-a-Service 방식을 선택한다. 본 시스템은 응급 진단기가 아니라 상담 준비용 위험 신호 요약 시스템이므로 수백 밀리초 수준의 서버 응답 지연은 허용 가능하다.

관점	MaaS 선택 근거
지연 시간	Logistic Regression 모델의 단건 추론은 < 10ms로, 네트워크 오버헤드를 포함해도 상담 준비 워크플로에서는 수백 밀리초의 응답 지연이 충분히 허용된다.
개인정보(PHI)	환자 임상 데이터(PHI)를 온디바이스에 저장하는 것보다 중앙화된 보안 서버에서 처리 후 즉시 파기하는 방식이 HIPAA 준수 측면에서 관리하기 용이하다. 접근 로그, 감사 추적, 암호화 전송, 최소 보관 정책을 일관되게 적용할 수 있다.

업데이트 주기	threshold와 모델 artifact가 바뀌어도 서버 단에서 한 번 배포하면 모든 클라이언트가 최신 모델을 사용한다.
---------	---

On-Device 배포도 오프라인 가용성과 네트워크 독립성 면에서 의미 있는 장점을 가진다. 그러나 CardioCare의 사용 환경(병원 내 유선 네트워크가 구축된 상담실)을 고려하면 오프라인 요건은 실질적 제약이 아니다. 반면 수만 개 단말에 걸친 모델 파일 동기화, 단말별 PHI 저장 관리, 버전 불일치 위험은 On-Device의 구체적인 운영 부담이다. 결론적으로 지연 시간 허용 가능 + PHI 중앙 관리 용이 + 업데이트 주기 단순화 세 관점 모두에서 MaaS 아키텍처가 CardioCare에 최적이다.

8. 한계, 윤리적 고려 사항, 개선 방향

- 기술적 한계: Cleveland 303 행은 5-fold CV 기준 훈련셋이 약 194 행에 불과하여 딥러닝 적용이 불가능하고, 특성 수(13 개)가 많아질수록 과적합 위험이 높다. 또한 1988 년 Cleveland 병원 단일 기관 데이터이므로, 다른 인종·지역·시대의 환자에게 적용 시 성능 저하가 예상된다. 실제 임상 배포 전에 목표 집단의 데이터로 재검증이 필수다.
- 정적 특성 한계: 혈압 하나만도 아침·저녁, 운동 전·후에 따라 크게 달라진다. 현재 모델은 단일 시점 측정값만 사용하므로 혈압 추이, 콜레스테롤 변화율, 운동 내성의 시계열적 변화 같은 동적 임상 정보를 반영하지 못한다. 장기적 위험 변화 추적에는 순환 신경망(LSTM)이나 시계열 특성 공학이 필요하다.
- 윤리 원칙: Inform, not Decide. 예측 결과는 의료진 판단을 보조하는 참고 정보이며 자동화된 의료 결정에 사용하지 않는다. UI 에 "이 결과는 의사의 진단을 대신하지 않습니다"를 명시하고, 고위험 판정 시에도 "전문의 상담을 강력히 권고합니다"라는 안내 문구가 함께 표시된다.
- 공정성: 성별, 나이대별 confusion matrix 와 recall 차이를 주기적으로 점검해야 한다. Cleveland 데이터셋에서 여성 비율은 약 32%(97 명)에 불과해 여성 하위 그룹의 성능이 남성보다 낮을 가능성이 있다. 배포 후 모니터링 단계에서 성별·나이대(40 대/50 대/60 대) 분류별 recall 을 정기 보고서로 생성하여 편향 강화를 조기에 탐지해야 한다.
- 투명성(Transparency): 모델 버전, 학습 데이터 버전, 예측 확률을 항상 함께 제공하여 의사가 예측의 불확실성을 인지할 수 있도록 한다.
- 응급 우선(Safety First): 응급 증상이 입력될 경우 모델 확률을 무시하고 즉각적인 전문 진료 안내를 최우선한다.
- 한 주가 더 주어진다면 ① SHAP/계수 기반 개별 설명(각 예측에 대한 특성 기여도 시각화), ② 나이대(40 대·50 대·60 대)·성별로 분류된 하위 그룹 공정성

감사(confusion matrix 비교), ③ UCI 통합 버전(Cleveland + Hungary + Switzerland + VA)으로 일반화 성능 향상, ④ calibration curve 로 확률 신뢰도 검증, ⑤ FastAPI 서빙 엔드포인트 구현, ⑥ Evidently AI 실시간 드리프트 모니터링 대시보드를 추가한다.

AI 도구 사용 공개: 본 과제에서는 ChatGPT와 Claude를 활용하였으며, 문서 초안 정리 및 코드 디버깅에 사용하였다.

참고 자료

- UCI Machine Learning Repository - Heart Disease Dataset: <https://archive.ics.uci.edu/dataset/45/heart+disease>
- CDC - Heart Disease Prevention: <https://www.cdc.gov/heart-disease/prevention/index.html>
- American Heart Association - Life's Essential 8: <https://www.heart.org/en/healthy-living>
- American Heart Association - Heart Attack Warning Signs: <https://www.heart.org/en/health-topics/heart-attack/warning-signs-of-a-heart-attack>
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825-2830.
- MLflow Documentation: <https://mlflow.org/docs/latest/index.html>
- GitHub Repository: https://github.com/yunjae305/ML_FINAL